

## Sommaire

- I. Introduction
- II. Modèle de Cox-Ross-Rubinstein
- III. Arrêt optimal et option américaine
- IV. Algorithme de Longstaff-Schwartz
- V. Réseau de neurones

# Plan

## Introduction

## Modèle de Cox-Ross-Rubinstein

## Arrêt optimal et option américaine

## Algorithme de Longstaff Schwartz

## Réseaux de neurones

## Introduction

- Option : titre financier qui donne à son détenteur le droit d'acheter ou de vendre
- Nature de l'option : option de call pour une option d'achat et option de put pour une option de vente
- On peut distinguer les options selon leur date d'expiration:
  - option américaine: l'option peut être exercée à n'importe quel instant avant l'échéance
  - option européenne: l'option ne peut être exercée qu'à la date d'expiration

## Hypothèses et paramètres

- Le marché est complet.

## Hypothèses et paramètres

- Le marché est complet.
- $r$  le taux d'intérêt sans risque;
- $\sigma$  la volatilité;

## Hypothèses et paramètres

- Le marché est complet.
- $r$  le taux d'intérêt sans risque;
- $\sigma$  la volatilité;
- $T$  temps de maturité;
- $N$  nombre de pas de temps;
- $S_n$  prix de l'action à l'instant  $n\frac{T}{N}$ , ou vecteur des prix en cas de panier d'actions;
- $K$  prix d'exercice.
- - Option de call:  $\text{payoff}(S, K) = (S - K)_+$   
- Option de put:  $\text{payoff}(S, K) = (K - S)_+$

# Plan

Introduction

Modèle de Cox-Ross-Rubinstein

Arrêt optimal et option américaine

Algorithme de Longstaff Schwartz

Réseaux de neurones

## Modèle de Cox-Ross-Rubinstein en dimension 1

À chaque instant  $n$ , le cours de l'actif peut soit augmenter d'un facteur  $u$  avec proba  $p$ , soit diminuer d'un facteur  $d$  avec proba  $1 - p$ , tq  $u > d > 0$




Figure: Arbre binomiale du modèle de Cox Ross pour  $N=3$

Le prix de l'actif  $(S_n)_{n \in \mathbb{N}}$  suit le processus dynamique stochastique suivant:

$$\forall n \in \mathbb{N}, S_{n+1} = S_n \cdot (u \cdot \mathbf{1}_{\{U_{n+1}=1\}} + d \cdot \mathbf{1}_{\{U_{n+1}=0\}})$$

avec  $(U_n)_{n \in \mathbb{N}}$  une suite de variables aléatoires iid suivant une loi de Bernoulli de paramètre  $p$ .



## Implémentation

La valeur de l'actif correspond à  $u(0, S_0)$ .

La valeur de l'actif à chaque instant  $n$  vérifie l'algorithme de programmation dynamique suivant:


- Pour une option européenne:

$$\begin{cases} u(N, x) &= \text{payoff}(x, K) \\ u(n, x) &= \frac{pu(n+1, xu) + (1-p)u(n+1, xd)}{1+r} \end{cases}$$

- Pour une option américaine:

$$\begin{cases} u(N, x) &= \text{payoff}(x, K) \\ u(n, x) &= \max(\text{payoff}(x, K), \frac{pu(n+1, xu) + (1-p)u(n+1, xd)}{1+r}) \end{cases}$$

## Convergence du modèle de Cox-Ross-Rubinstein vers le modèle de Black-Scholes pour une option européenne

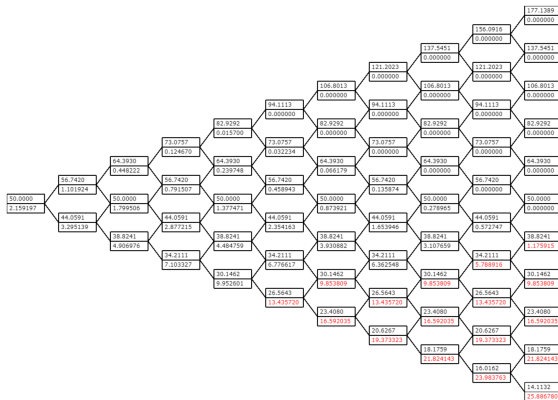


**Figure:** Convergence de CRR vers BS: variation du prix du put **eupéen** en fonction de  $N$  avec les paramètres  $S_0 = 50$ ,  $K = 40$ ,  $r = 0.1$ ,  $\sigma = 0.4$ ,  $T = 1$

```
Number of steps used in Binomial Model: N = 1000
European call Binomial:      15.800194179898709
European call Analytic (BS): 15.800068798345148
European put Binomial:       1.9936909013350086
European put Analytic (BS):  1.9935655197835285
Call-put parity for binomial: c-p= 13.8065032785637
S0 exp(-qT)- K exp(-rT)= 13.806503278561621
```

**Figure:** Comparaison des résultats obtenus avec le modèle de CCR et le modèle de BS avec les paramètres  $S_0 = 50$ ,  $K = 40$ ,  $r = 0.1$ ,  $\sigma = 0.4$ ,  $T = 1$

## Résultats pour une option américaine



**Figure:** Arbre binomiale du modèle de Cox Ross pour le pricing d'un **put américain** avec les paramètres  $S_0 = 50$ ,  $K = 40$ ,  $r = 0.1$ ,  $\sigma = 0.4$ ,  $T = 1$ ,  $N = 10$ .

Dans chaque noeud, on trouve en haut le prix de l'action, en bas la valeur de l'option. Les noeuds **en rouge** correspondent aux noeuds où il est optimal d'exercer.

## Modèle de Cox-Ross-Rubinstein en dimension supérieure

- Dans le cas où le sous-jacent de l'option est un panier de  $d$  actions, on considère le processus  $S_n = (S_n^1, \dots, S_n^d)$  où  $S_n^i$  est le cours de l'action  $i$  à l'instant  $n$ . On fait l'hypothèse que les  $S_n^i, 1 \leq i \leq d$  sont indépendantes.

## Modèle de Cox-Ross-Rubinstein en dimension supérieure

- Dans le cas où le sous-jacent de l'option est un panier de  $d$  actions, on considère le processus  $S_n = (S_n^1, \dots, S_n^d)$  où  $S_n^i$  est le cours de l'action  $i$  à l'instant  $n$ . On fait l'hypothèse que les  $S_n^i, 1 \leq i \leq d$  sont indépendantes.
- Dans le cas  $d=2$ , le couple  $(S_{n+1}^1, S_{n+1}^2)$  est égal à:
  - $(u_1 S_n^1, u_2 S_n^2)$  avec proba  $p_1 p_2$
  - $(u_1 S_n^1, d_2 S_n^2)$  avec proba  $p_1 (1 - p_2)$
  - $(d_1 S_n^1, u_2 S_n^2)$  avec proba  $(1 - p_1) p_2$
  - $(d_1 S_n^1, d_2 S_n^2)$  avec proba  $(1 - p_1)(1 - p_2)$

## Modèle de Cox-Ross-Rubinstein en dimension supérieure

- Dans le cas où le sous-jacent de l'option est un panier de  $d$  actions, on considère le processus  $S_n = (S_n^1, \dots, S_n^d)$  où  $S_n^i$  est le cours de l'action  $i$  à l'instant  $n$ . On fait l'hypothèse que les  $S_n^i, 1 \leq i \leq d$  sont indépendantes.
- Dans le cas  $d=2$ , le couple  $(S_{n+1}^1, S_{n+1}^2)$  est égal à:
  - $(u_1 S_n^1, u_2 S_n^2)$  avec proba  $p_1 p_2$
  - $(u_1 S_n^1, d_2 S_n^2)$  avec proba  $p_1 (1 - p_2)$
  - $(d_1 S_n^1, u_2 S_n^2)$  avec proba  $(1 - p_1) p_2$
  - $(d_1 S_n^1, d_2 S_n^2)$  avec proba  $(1 - p_1)(1 - p_2)$
- Complexité exponentielle :  $O(2^{dN})$

# Plan

Introduction

Modèle de Cox-Ross-Rubinstein

**Arrêt optimal et option américaine**

Algorithme de Longstaff Schwartz

Réseaux de neurones

## Arrêt optimal et option américaine

- On note  $(Z_n = f(n, S_n))_{0 \leq n \leq N}$  le processus des *payoff* actualisés. On a:  
$$Z_n = f(n, S_n) = e^{-r \frac{nT}{N}} \text{payoff}(S_n, K)$$
- On suppose que le processus des payoff actualisés  $(Z_n)$  est adapté à la filtration  $(F_n)$  et que  $\mathbb{E}[\max_{0 \leq n \leq N} |Z_n|^2] < +\infty$ .



## Arrêt optimal et option américaine

- On note  $(Z_n = f(n, S_n))_{0 \leq n \leq N}$  le processus des *payoff* actualisés. On a:  

$$Z_n = f(n, S_n) = e^{-r \frac{nT}{N}} \text{payoff}(S_n, K)$$
- On suppose que le processus des *payoff* actualisés  $(Z_n)$  est adapté à la filtration  $(F_n)$  et que  $\mathbb{E}[\max_{0 \leq n \leq N} |Z_n|^2] < +\infty$ .
- Dans un marché complet, si  $\mathbb{E}$  dénote l'espérance sous la probabilité risque neutre, la valeur de l'option à l'instant  $n$  s'écrit:

$$u(n, S_n) = \sup_{\tau \in \mathcal{T}_n} \mathbb{E}[f(\tau, S_\tau) | F_n \text{ ou } S_n]$$

## Arrêt optimal et option américaine

- On note  $(Z_n = f(n, S_n))_{0 \leq n \leq N}$  le processus des *payoff* actualisés. On a:  

$$Z_n = f(n, S_n) = e^{-r \frac{nT}{N}} \text{payoff}(S_n, K)$$
- On suppose que le processus des payoff actualisés  $(Z_n)$  est adapté à la filtration  $(F_n)$  et que  $\mathbb{E}[\max_{0 \leq n \leq N} |Z_n|^2] < +\infty$ .
- Dans un marché complet, si  $\mathbb{E}$  dénote l'espérance sous la probabilité risque neutre, la valeur de l'option à l'instant  $n$  s'écrit:

$$u(n, S_n) = \sup_{\tau \in \mathcal{T}_n} \mathbb{E}[f(\tau, S_\tau) | F_n \text{ ou } S_n]$$

En appliquant la théorie de l'enveloppe de Snell, la valeur de l'option américaine  $u(0, S_0)$  est donnée par le problème de programmation dynamique:

$$\begin{cases} u(N, S_N) &= f(N, S_N) \\ u(n, S_n) &= \max( f(n, S_n), \mathbb{E}[ u(n+1, S_{n+1}) | S_n ] ) \end{cases} \quad (1)$$

## Algorithme de programmation dynamique

Soit  $\tau_j^*$  le temps d'arrêt optimal après l'instant  $j$ , tel que

$$\tau_j^* = \min\{n \geq j \mid u(n, S_n) = f(n, S_n)\}$$

## Algorithme de programmation dynamique

Soit  $\tau_j^*$  le temps d'arrêt optimal après l'instant  $j$ , tel que

$$\tau_j^* = \min\{n \geq j \mid u(n, S_n) = f(n, S_n)\}$$

On a:

$$u(j, S_j) = \mathbb{E}[f(\tau_j^*, S_{\tau_j^*}) \mid S_j] \quad (2)$$

En utilisant les temps d'arrêt optimaux, l'algorithme (1) s'écrit:

$$\begin{cases} \tau_N^* &= N \\ \tau_j^* &= j \mathbf{1}_{\{f(j, S_j) \geq u(j, S_j)\}} + \tau_{j+1}^* \mathbf{1}_{\{f(j, S_j) < u(j, S_j)\}} \end{cases}$$

## Algorithme de programmation dynamique

Soit  $\tau_j^*$  le temps d'arrêt optimal après l'instant  $j$ , tel que

$$\tau_j^* = \min\{n \geq j \mid u(n, S_n) = f(n, S_n)\}$$

On a:

$$u(j, S_j) = \mathbb{E}[f(\tau_j^*, S_{\tau_j^*}) \mid S_j] \quad (2)$$

En utilisant les temps d'arrêt optimaux, l'algorithme (1) s'écrit:

$$\begin{cases} \tau_N^* &= N \\ \tau_j^* &= j \mathbf{1}_{\{f(j, S_j) \geq u(j, S_j)\}} + \tau_{j+1}^* \mathbf{1}_{\{f(j, S_j) < u(j, S_j)\}} \end{cases}$$

On se débarrasse de  $u(j, S_j)$  en utilisant les formules (1) et (2), on obtient:

$$\begin{cases} \tau_N^* &= N \\ \tau_j^* &= j \mathbf{1}_{\{f(j, S_j) \geq \mathbb{E}[f(\tau_{j+1}^*, S_{\tau_{j+1}^*} \mid S_j)]\}} \\ &+ \tau_{j+1}^* \mathbf{1}_{\{f(j, S_j) < \mathbb{E}[f(\tau_{j+1}^*, S_{\tau_{j+1}^*} \mid S_j)]\}} \end{cases} \quad (3)$$

# Plan

Introduction

Modèle de Cox-Ross-Rubinstein

Arrêt optimal et option américaine


Algorithme de Longstaff Schwartz

Réseaux de neurones

## Méthode de Monte Carlo

$$\frac{dS_t}{S_t} = rdt + \sigma dW_t$$

Lognormal generated paths for MC



**Figure:** 10000 trajectoires lognormales d'une action avec les paramètres  $S_0 = 50$ ,  $\sigma = 0.4$ ,  $r = 0.1$ ,  $T = 1$

## Schéma de l'algorithme

Générer  $M$  trajectoires de l'action  $(S_j^{(m)}, 0 \leq j \leq N), 1 \leq m \leq M$



Approximer  $\mathbb{E}[f(\tau_{j+1}^{(m)}, S_{\tau_{j+1}^{(m)}}^{(m)}) | S_j]$



Trouver les temps d'arrêt optimaux  $\tau_j^{(m)}, 1 \leq j \leq N$



Déduire la valeur de l'option américaine

$$\text{Option value} = \frac{1}{M} \sum_{m=1}^M f(\tau_0^{(m)}, S_{\tau_0^{(m)}}^{(m)})$$



## Algorithme de Longstaff Schwartz

- L'idée basique de Longstaff Schwartz est d'introduire une **méthode des moindres carrés**.

## Algorithme de Longstaff Schwartz

- L'idée basique de Longstaff Schwartz est d'introduire une **méthode des moindres carrés**.

- On cherche  $\phi_j$  dans  $L^2$ ( loi de  $S_j$ ) tq  $\phi_j(S_j) = \mathbb{E}[f(\tau_{j+1}^*), S_{\tau_{j+1}^*} | S_j]$ .

-  $L^2$  étant un espace Hilbert,  $\phi_j(S_j)$  peut être calculé en minimisant  $\mathbb{E}[(f(\tau_{j+1}^*), S_{\tau_{j+1}^*}) - \phi_j(S_j)]^2$ , en pratique cela revient à minimiser  $\sum_{m=1}^M (f(\tau_{j+1}^{(m)}, S_{\tau_{j+1}^{(m)}}^{(m)}) - \phi_j(S_j^{(m)}))^2$  avec l'approximation de Monte-Carlo.

## Algorithme de Longstaff Schwartz

- L'idée basique de Longstaff Schwartz est d'introduire une **méthode des moindres carrés**.

- On cherche  $\phi_j$  dans  $L^2$ ( loi de  $S_j$ ) tq  $\phi_j(S_j) = \mathbb{E}[f(\tau_{j+1}^*), S_{\tau_{j+1}^*} | S_j]$ .

-  $L^2$  étant un espace Hilbert,  $\phi_j(S_j)$  peut être calculé en minimisant  $\mathbb{E}[(f(\tau_{j+1}^*), S_{\tau_{j+1}^*}) - \phi_j(S_j)]^2$ , en pratique cela revient à minimiser  $\sum_{m=1}^M (f(\tau_{j+1}^{(m)}, S_{\tau_{j+1}^{(m)}}^{(m)}) - \phi_j(S_j^{(m)}))^2$  avec l'approximation de Monte-Carlo.

- Avec  $(g_l, l \geq 1)$  une base hilbertienne de  $L^2$ , on écrit  $\phi_j = \sum_{l \geq 1} \alpha_l g_l$ .

## Algorithme de Longstaff Schwartz

- L'idée basique de Longstaff Schwartz est d'introduire une **méthode des moindres carrés**.

- On cherche  $\phi_j$  dans  $L^2$ ( loi de  $S_j$ ) tq  $\phi_j(S_j) = \mathbb{E}[f(\tau_{j+1}^*), S_{\tau_{j+1}^*} | S_j]$ .

-  $L^2$  étant un espace Hilbert,  $\phi_j(S_j)$  peut être calculé en minimisant  $\mathbb{E}[(f(\tau_{j+1}^*), S_{\tau_{j+1}^*}) - \phi_j(S_j)]^2$ , en pratique cela revient à minimiser  $\sum_{m=1}^M (f(\tau_{j+1}^{(m)}, S_{\tau_{j+1}^{(m)}}^{(m)}) - \phi_j(S_j^{(m)}))^2$  avec l'approximation de Monte-Carlo.

- Avec  $(g_l, l \geq 1)$  une base hilbertienne de  $L^2$ , on écrit  $\phi_j = \sum_{l \geq 1} \alpha_l g_l$ .

## Implémentation

**Data:**  $M$  trajectoires simulées

**Result:** le calcul des temps optimaux  $\tau_j^*$

**Initialization:**  $\tau_N^m \leftarrow N$  pour  $0 \leq m \leq M, j \leftarrow N - 1$

**while**  $j \geq 1$  **do**

*Trouver le polynôme  $\phi$  qui minimise*

$$\sum_{m=1}^M (f(\tau_{j+1}^{(m)}, S_{\tau_{j+1}^{(m)}}^{(m)}) - \phi(X_j^{(m)}))^2$$

**for** *chaque trajectoire*  $m$  **do**

**if**  $f(j, S_j^{(m)}) \geq \phi(S_j^{(m)})$  **then**

$\tau_j^{(m)} \leftarrow j$

**else**

$\tau_j^{(m)} \leftarrow \tau_{j+1}^{(m)}$

**end**

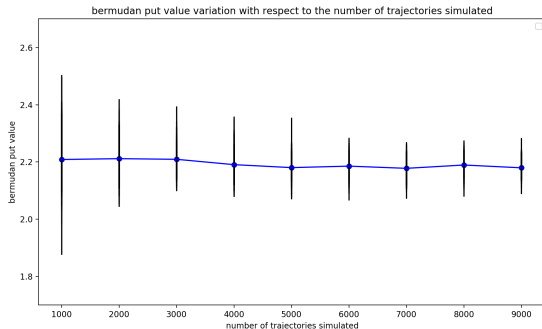
**end**

$j \leftarrow j - 1$

**end**

**Algorithm 1:** Calcul des temps optimaux

## Résultats



**Figure:** évolution du prix d'un put bermudéen en fonction de  $M$  le nombre de trajectoire généré, le prix est calculé 50 fois pour chaque valeur de  $M$  avec nouvelle génération de trajectoires à chaque fois, en bleu la moyenne des valeurs obtenus pour chaque  $M$ , rappel:  $S_0 = 50$ ,  $K = 40$ ,  $\sigma = 0.4$ ,  $r = 0.1$ ,  $T = 1\text{an}$ ,  $N = 10$

## Dimension Supérieure

Dans le cas d'une option sur un panier de  $d$  actions, on suppose que chaque actif de prix  $S_t^i$  suit un modèle de Black Scholes guidé par un mouvement  $W_t^i$ ,

## Dimension Supérieure

Dans le cas d'une option sur un panier de  $d$  actions, on suppose que chaque actif de prix  $S_t^i$  suit un modèle de Black Scholes guidé par un mouvement  $W_t^i$ , de sorte que:

- $(W_t, t > 0)$  un mouvement brownien d-dimensionnel de composants indépendants
- une matrice  $\Sigma$  de taille  $d \times d$

$$\frac{dS_t^i}{S_t^i} = rdt + [\Sigma W_t]_i \quad (4)$$

1. On génère M trajectoires du vecteur  $S_n = (S_n^0, \dots, S_n^d)$  à l'aide de (4)
2. on applique l'algorithme de Longstaff Schwartz avec  $\phi_j$  un polynôme à d variables.

par exemple, si  $d=2$  on cherche  $\phi_j$  sous la forme de combinaison linéaire de  $\{1, X_1, X_2, X_1^2, X_2^2, X_1X_2, X_1^3, X_2^3, X_1^2X_2, X_1X_2^2, \dots\}$



# Plan

Introduction

Modèle de Cox-Ross-Rubinstein

Arrêt optimal et option américaine

Algorithme de Longstaff Schwartz

**Réseaux de neurones**

## Pourquoi les réseaux de neurones?


- La régression repose sur la composition **linéaire** en couches de fonctions simples, polynômes par exemple.
- Le but derrière DNN est d'approximer des fonctions **non linéaires** assez complexes.
- Théorème d'approximation universel.
- Les DNN ne subissent pas (en principe) la malédiction des dimensions élevées.

## Approximation d'une espérance conditionnelle par réseaux de neurones

- On remplace la partie régression linéaire dans l'algorithme de Longstaff Schwartz par un réseau de neurones pour approximer  $\mathbb{E}[f(\tau_{j+1}^*, S_{\tau_{j+1}^*}) | S_j]$ .
- Le réseau est entraîné par le couple  $(S_j^{(m)}, f(\tau_{j+1}^{(m)}, S_{\tau_{j+1}^{(m)}}^{(m)}))$  afin de trouver la fonction  $\phi_j$  qui approxime l'espérance conditionnelle.

## Implémentation

Après plusieurs expérimentations, on a choisi de prendre un réseau de neurones de la forme:



Input Layer  $\in \mathbb{R}^1$

Hidden Layer  $\in \mathbb{R}^4$

Hidden Layer  $\in \mathbb{R}^4$


Output Layer  $\in \mathbb{R}^1$

avec la fonction d'activation:

$$elu(x) = \begin{cases} x & \text{si } x \geq 0 \\ e^x - 1 & \text{si } x < 0 \end{cases}$$

## Implémentation

Après plusieurs expérimentations, on a choisi de prendre un réseau de neurones de la forme:




avec la fonction d'activation:

$$elu(x) = \begin{cases} x & \text{si } x \geq 0 \\ e^x - 1 & \text{si } x < 0 \end{cases}$$

On a utilisé la bibliothèque **keras** pour implémenter ce RN.

## résultats

bermudan put value variation with respect to the number of trajectories simulated (neural network)



**Figure:** Réseau de neurones: évolution du prix d'un put bermudéen en fonction de  $M$  le nombre de trajectoire généré, le prix est calculé 10 fois pour chaque valeur de  $M$  avec nouvelle génération de trajectoires à chaque fois, en bleu la moyenne des valeurs obtenus pour chaque  $M$ , rappel:  $S_0 = 50$ ,  $K = 40$ ,  $\sigma = 0.4$ ,  $r = 0.1$ ,  $T = 1\text{an}$ ,  $N = 3$

## Dimension supérieure

Pour une option sur un panier de  $d$  actions, on génère  $M$  trajectoires de  $S_n = (S_n^1, \dots, S_n^d)$  selon le modèle de Black Scholes, ensuite on adapte notre RN en prenant:

- une couche d'entrée de  $d$  neurones.
- une 1ère couche intermédiaire de  $4d$  neurones.
- une 2ème couche intermédiaire de  $4d$  neurones.
- une couche de sortie contenant 1 neurone.